





Francisco J. Toro López

## CIENCIA DE LOS DATOS CON PYTHON

Francisco J. Toro López

Toro López, Francisco J.

Ciencia de los datos con Python / Francisco J. Toro López. -- 1a ed. -- Bogotá: Ecoe Ediciones, 2022.

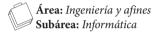
201 p. – (Ingeniería y afines. Informática)

Contiene datos curriculares del autor. -- Contiene referencias bibliográficas.

ISBN 978-958-503-356-6 -- 978-958-503-357-3 (e-book)

1. Minería de datos - Técnicas 2. Búsquedas en bases de datos 3. Python (Lenguaje de programación de computadores) I. Título II. Serie

CDD: 006.312 ed. 23 CO-BoBN- a1090613





© Francisco J. Toro López

► Ecoe Ediciones S.A.S. info@ecoeediciones.com www.ecoeediciones.com Carrera 19 # 63C 32, Tel.: 919 80 02 Bogotá, Colombia

Primera edición: Bogotá, mayo del 2022

ISBN: 978-958-503-356-6 e-ISBN: 978-958-503-357-3

Directora editorial: Claudia Garay Castro Coordinadora editorial: Paula Bermúdez B. Corrección de estilo: Andrés Caro Diagramación: Magda Rocío Barrero Carátula: Wilson Marulanda Muñoz Impresión: Carvajal Soluciones de Comunicación S.A.S.

Carrera 69 #15-24

Prohibida la reproducción total o parcial por cualquier medio sin la autorización escrita del titular de los derechos patrimoniales.

Impreso y hecho en Colombia - Todos los derechos reservados

#### **DEDICATORIA**

A mis padres, Darío Toro Ossa y Lucila López de Toro (QEPD), a mis hermanos Rubén e Iván por el abierto e incondicional apoyo en mi formación profesional, sentimental y personal.

Por su cariñosa y siempre amable aptitud de ayudarme a descubrir lo que es fundamental en nuestras vidas, a mi hija, Viviana Alejandra, a mi Myriam Abondano, Myriam Guzmán, Javier Llorca y Esposa Jimena, a mis sobrinos Mauricio y Camila Toro; Claudio, Oscar y Nicolás Rodríguez; Julián y Paola Beltrán; Enrique, Jorge Eduardo y Andrés Abondano, y María Paula y Gaby Guzmán.

Un agradecimiento especial y cariñoso a María Constanza García y a Claudia Quiroga por su gracioso y entretenedor esparcimiento con la música en los ratos algo diferentes de las labores de investigación que exige escribir un libro sobre estos temas.

#### **AGRADECIMIENTOS**

El autor expresa formalmente sus agradecimientos a los ingenieros Fernando Salazar D., Germán Moreno y Héctor Beltrán por su valiosa cooperación y comentarios que sirvieron para dar una mejor presentación y, posteriormente, una adecuada elaboración del material textual y gráfico de la obra.

Así mismo, un especial reconocimiento a los administradores de los programas de capacitación del EdX, entre los que se distinguen IBM y la Universidad de Harvard, por el aporte que recibí al tomar varios de sus cursos y el suministro de material valioso, empleado en la presentación de diversas explicaciones y temas sobre los procedimientos y herramientas usualmente encontrados en **Python** y **Microsoft Project.** 

#### **CONTENIDO**

OBSERVACIONES GENERALES	XXI
Introducción	XXV
Capítulo 1. El lenguaje Python	
Introducción al manejo de Python	3
Instalación de Python	5
El editor IDLE	8
Tipos de datos	8
Ejercicios	10
Las cadenas de caracteres	11
Valores booleanos (bool)	13
La interfaz de Python	14
La versión de Python en uso	17
Escribir comentarios en Python	18
Errores en Python	19
¿Python sabe de un error antes de que se ejecute el código?	20
Manejo de caracteres	20
Escribir el primer programa con Python	20
Tipos de objetos en Python	21
Manejo de cadenas de caracteres	22
Listas y tuplas	24
Funcionas integradas	25

Funciones básicas matemáticas	36
Operadores de comparación	38
Operadores de identidad y pertenencia	39
Manejo de diccionarios	40
Colecciones (set) de datos	44
Observaciones sobre secuencias: cadenas, listas y tuplas	50
Paquetes complementarios de Python	51
Resumen de Python en la ciencia de los datos	52
Funciones	54
Apertura de archivos	58
Leyendo Archivos	60
Programas en red	61
El protocolo de transporte de hipertexto (HTTP)	61
El navegador web más sencillo	62
Análisis de html y barrido de la web	64
Análisis de HTML mediante BeautifulSoup	65
Los programas	66
Uso de objetos	67
Comenzando a Programar	68
Subdividir un problema - Encapsulación	70
Los objetos Python	71
Depuración (debugging)	71
Glosario	72
Capítulo 2. Términos, técnicas y tareas de las ciencias	
DE DATOS	75
¿Qué es la minería de datos?	76
¿Qué es la ciencia de los datos?	77
Los Científicos de datos	77
Big Data	80
Nuevos dispositivos	81
El Big Data requiere de un Big Analytics	81
Las limitaciones del business intelligence tradicional	82
La evolución del DWH al ADW	83
MAD, nueva metodología	83
Medio Magnético	83
Ágil	84
Detallado	84
Hadoop	84
HDFS	85
MAPREDUCE	85
La Ciencia de los Datos.	89

Adquisición de datos: paso 1	99
Manipulación de datos: paso 2	
Aplicación de técnicas de análisis: paso 3	
Reportar la información: paso 4	
En acción: paso 5	
Capítulo 3. Adquisición y manipulación de datos	121
Importación y exportación de datos con Python	122
Caso 1: análisis de datos	122
Introducción al análisis de datos con Python	125
Caso 2: El Castillo de Edimburgo	125
Inicio del análisis	126
Desmembrando todo	126
Capítulo 4. Análisis de los datos y diseño y	
PRESENTACIÓN DEL MODELO	129
Verificando la instalando Python	129
Recomendaciones para Windows	130
La integración	131
Convertir los resultados en acción	131
Las diferencias de las métricas dependiendo de las variables y tareas	142
Datos históricos + datos cercanos a la realidad → predicciones	142
Eliminar filas en el DataFrame Claudia con base a sus valores	143
Conjunto de datos de ejemplo	143
Capítulo 5. Evaluación de modelos: la vista 'minable'	
Y LA COMPRENSIÓN DE DATOS	
¿Qué es la vista minable?	
¿Para qué se utiliza una vista 'minable'?	148
Técnicas que convierten datos en modelos y procesos de	
predicción en temas empresariales	150
Análisis exploratorio	150
Métodos de estimación y predicción	
Un caso manejado con tres técnicas matemáticas	153
Alisado exponencial simple	
Capítulo 6. Proyectos de las ciencias de datos	161
Planeación y desarrollo de proyectos de la ciencia de los datos	161
Definición ampliada de las delimitaciones	163
Tiempos, costos y riesgos de proyectos	
Las fases de un proyecto	
Definición y creación del plan básico del provecto	

Ajustes e informes	170
Desarrollo y supervisión del proyecto	170
Cierre y evaluación de un proyecto	171
Metodologías empleadas para administrar proyectos	171
La asignación de recursos	174
Los costos de un proyecto	177
Caso del palacio de Edimburgo	185
Anexos	189
Referencias	199

### ÍNDICE DE FIGURAS

rigura 1.	Cargue del editor IDLE de información	0
Figura 2.	Tres tipos de datos en Python	8
Figura 3.	Datos numéricos enteros	9
Figura 4.	Datos numéricos flotantes	9
Figura 5.	Tipos de datos más comunes	9
Figura 6.	Datos numéricos enteros	. 10
Figura 7.	Cadenas de datos flotantes	. 11
Figura 8.	Convirtiendo flotantes a enteros	. 11
Figura 9.	Usando el comando tipo booleano	. 13
Figura 10.	Asignar un "0" a un dato booleano, se consigue un "False"	. 14
Figura 11.	Un pequeño código fuente	. 15
Figura 12.	Cargue del programa Python	. 17
Figura 13.	Los caracteres de una cadena son indexados	. 20
Figura 14.	Los elementos de una tupla son indexados	. 24
Figura 15.	El tipo de una tupla es siempre TUPLA	. 25
Figura 16.	Se accede al elemento de una tupla por su índice	. 25
Figura 17.	Concatenando dos tuplas se puede realizar	. 26

Figura 18.	Eliminando elementos de una tupla	26
Figura 19.	Dejando a un lado elementos de una tupla	26
Figura 20.	Dejando a un lado elementos de una tupla	26
Figura 21.	Uso de la función "len" en una tupla	27
Figura 22.	Las tuplas son inmutables	27
Figura 23.	Las tuplas son inmutables	27
Figura 24.	Como las tuplas son inmutables, si se quiere cambiar una, hay que crearla	28
Figure 25	Ordenando una tupla	
	Anidando una tupla en otra	
	Accesando un elemento anidado en una tupla	
•	Accesando elementos anidados en una lista	
· ·	Acceso a un elemento anidado en una tupla	
_		
_	La relación entre un índice y los elementos de una lista	
U	Uso de un índice negativo en un elemento de una lista ( <i>List</i> )	
·	Segmentando un elemento de una lista	
-	Convenciones de índice de una lista	
-	Concatenar o combinar listas de datos	
	Cambiando elementos de una lista	
_	Concatenando una lista a otra, usando el método extend	
	Cambiando listas a otra lista con extend	
	Agregando elementos a otra lista con append	
	Modificando una lista con extend	
-	Modificando una cadena a una lista con extend y append	
_	Eliminando un elemento de una Lista con "del"	
Figura 42.	Agregando un elemento a una lista, usando índices	33
Figura 43.	Con la función Split se separan elementos de una lista	34
Figura 44.	Con la función Split se cambian elementos de una lista	34
Figura 45.	Con la función de alias, se cambian elementos de una lista	34
Figura 46.	Con la función alias, se cambia un elemento de varias listas	35
Figura 47.	Copiando elementos de una lista a otra	35
Figura 48.	Con la función help se brinda información de una lista	35

XV

Figura 49.	La función Range() calcula el rango de valores consecutivos	
	de una serie	36
_	La creación de un diccionario en Python	
Figura 51.	Generación de un diccionario	41
Figura 52.	Características de un diccionario	41
Figura 53.	Datos de un diccionario	42
Figura 54.	Año de creación y título de un diccionario de películas	42
Figura 55.	Verificando si el título de una película está en un diccionario de películas	43
Figura 56.	Borrando el título de una película	43
Figura 57.	Mostrando todos los títulos de películas	43
Figura 58.	Muestra los contenidos de un conjunto de datos	44
Figura 59.	Una lista conforma un conjunto de datos	44
Figura 60.	Un conjunto de datos no repetidos y ordenados	45
Figura 61.	Eliminando un elemento de un conjunto, usando la función remove	45
Figura 62.	Verificando si un elemento del conjunto está, con la función in	46
Figura 63.	Verificando que un elemento del conjunto NO está con la función <i>in</i>	46
Figura 64.	Representación de un elemento del conjunto que sí está	46
Figura 65.	Interceptación de un elemento en varios conjuntos	47
Figura 66.	Interpretación de varios elementos en dos conjuntos	48
Figura 67.	Interceptación de varios elementos con Python	48
Figura 68.	Un nuevo álbum conteniendo varios elementos en dos albúmenes con Python	48
Figura 69.	Unión de conjuntos conteniendo elementos comunes con Python.	48
Figura 70.	Representación gráfica de la unión de conjuntos	49
Figura 71.	Representación gráfica de si un conjunto es subconjunto de otro	49
Figura 72.	Representación gráfica de uniones, o no, de conjuntos	50
Figura 73.	Python shell	52
Figura 74.	Python shell	52
Figura 75.	Siguiente posición	53
Figura 76.	Python usa sangría en lugar de corchetes	53

Figura 77.	Programa de valores de variables y no de tipos	53
Figura 78.	Programa que imprime los 11 valores del 0 al 10	54
Figura 79.	Programa definido con la función valor absoluto	54
Figura 80.	¡Programa que no devuelve nada!	55
Figura 81.	Programa que no devuelve nada	55
Figura 82.	Función valor absoluto	58
Figura 83.	Uso de sockets en archivos HTTP	63
Figura 84.	Estructura típica de un programa	69
Figura 85.	Uso de biblioteca urllib y otros objetos en archivos HTTP	70
Figura 86.	Confluencia de conocimientos requeridos en la ciencia de los datos	90
Figura 87.	Extensión de conocimientos requeridos en la ciencia de los datos	91
Figura 88.	Habilidades y conocimiento de un científico de datos	91
Figura 89.	Python vs. otras herramientas de la informática para el científico de datos	92
Figura 90.	Transformando los datos en conocimiento	
Figura 91.	Conjunto de datos etiquetados	97
Figura 92.	Adquirir los datos	100
Figura 93.	Manipulación de datos	102
Figura 94.	El manejo de datos inconsistentes	103
Figura 95.	Arreglando los datos inconsistentes	103
Figura 96.	Arreglando datos inconsistentes	104
Figura 97.	Escalando los valores de datos inconsistentes	104
Figura 98.	Transformando valores de datos inconsistentes	105
Figura 99.	Removiendo, combinando y agregando valores de datos	105
Figura 100	. Removiendo, combinando y agregando valores de datos	106
Figura 101	. Manipulando algunos valores de datos	106
Figura 102	Preparación de valores de datos inconsistentes	107
Figura 103	. Construyendo el modelo de datos	107
Figura 104	. Categorías de las técnicas del análisis de datos	108
Figura 105	La clasificación como técnica del análisis de datos	108

XVII

Figura 106.	del análisisdel análisis	109
Figura 107.	La regresión como técnica para observar algún fenómeno por grupos de edades	109
Figura 108.	La asociación como técnica para hallar asociaciones de datos	110
Figura 109.	Usando gráficos como técnica para analizar conexiones entre datos	111
Figura 110.	Tres pasos para construir el modelo de datos	111
Figura 111.	Combinando la clasificación y la regresión como técnicas del modelo	112
Figura 112.	La técnica de clúster: ¿tiene o no sentido su aplicación?	112
Figura 113.	Combinando la asociación y el análisis gráfico como técnica de modelo	112
Figura 114.	Evaluar los resultados obtenidos al aplicar técnicas al modelo	113
Figura 115.	Reportar los resultados obtenidos al aplicar técnicas	114
Figura 116.	Reportar y comunicar los resultados obtenidos	114
Figura 117.	¿Cómo se van a presentar los resultados obtenidos?	115
Figura 118.	Formato de presentación de los resultados obtenidos	115
Figura 119.	Las herramientas de visualización de los resultados obtenidos	116
Figura 120.	Las herramientas de manejo de los resultados obtenidos	117
Figura 121.	Aplicar los resultados obtenidos	118
Figura 122.	La implementación de una acción	118
Figura 123.	Medir y evaluar la implementación de una acción	119
Figura 124.	La evaluación de una acción	119
Figura 125.	Caso 1: planteamiento del problema	123
Figura 126.	Caso 1: adquisición y manipulación de datos	123
Figura 127.	Caso 1: adquisición de datos de precios	124
Figura 128.	Caso 1: modelo de datos y procesos de datos	124
Figura 129.	Instalación de Python en caso de detectar un problema	130
Figura 130.	Abriendo Anaconda Promo	130
Figura 131.	Ventana de Python	131
Figura 132.	Convertir visiones en acciones y conectar los resultados	132
Figura 133.	Herramientas tecnológicas empleadas para la toma de acciones	132

Figura 134.	. Algunas formas de implementar acciones	3
Figura 135.	Evaluar el impacto de una acción	3
Figura 136.	Determinar los siguientes pasos después de la evaluación de una acción	4
Figura 137.	Tiempo de observación (min) vs. duración del video 13	6
Figura 138.	Tiempo de observación (min) vs. duración del video 13	6
Figura 139.	. Variables, métodos y parámetros	8
Figura 140	Dos métodos de cadenas de caracteres	8
Figura 141.	Dos funciones de lower aplicadas a cadenas de caracteres	9
Figura 142.	Imprimiendo mediante un bucle de funciones de 0 a 10 13	9
Figura 143.	. Imprimiendo valores pares para el rango de valores 0 a 10 14	1
Figura 144.	. Imprimiendo valores modulo 3 para el rango de valores 0 a 10 14	1
Figura 145.	Propiedades y tipos	1
Figura 146	Se usan mediante una consulta automática	8
Figura 147.	La construcción de una vista minable mediante la escritura de un código (¿en Python?)14	9
Figura 148.	Pirámide de sabiduría, conocimiento, información y datos 14	9
Figura 149.	Predicción de una variable de interés	52
Figura 150.	Suavizado exponencial	<b>i</b> 4
Figura 151.	Suavizado exponencial: Parámetros	55
Figura 152.	Suavizado exponencial: Guardar	6
Figura 153.	Las dimensiones básicas de un proyecto	i3
Figura 154.	Procesos administrativos de un proyecto	7
Figura 155.	Fases de planeación, ejecución y control de un proyecto	0'
Figura 156.	Desglose de un proyecto de construcción de un edificio	'2
Figura 157.	Diagrama de Gantt aplicado a la construcción de un edificio 17	'2
Figura 158.	La ruta crítica en la construcción de un edificio17	'3
Figura 159.	Cantidad de recursos vs. duración de una tarea	'5
Figura 160.	Opciones de programación	'6
Figura 161.	Opciones de la carpeta "Avanzado"	7
Figura 162.	Tipos de costos dependiendo de su comportamiento 17	7
Figura 163.	. Tablas de información de Project	32

XIX

Figura 164. Ventana del menú principal de Project	183
Figura 165. Guía de plantillas de proyectos de Project	184
Figura 166. Diagrama de Grantt del proyecto Palacio de Edimburgo	187
Figura 167. Los recursos del proyecto Palacio de Edimburgo	187
Figura 168. Los costos del proyecto Palacio de Edimburgo	187
Figura 169. Los flujos de caja del proyecto Palacio de Edimburgo	188
Figura 170. Imágenes RGB	190
Figura 171. Manejo de imágenes en PC	190
Figura 172. Los cuadros pequeñísimos en cuadros (tiles)	191
Figura 173. Un pixel	191
Figura 174. Imagen RGB en Python	192
Figura 175. Importando imagen RGB	193
Figura 176. Modelando en WIFIRE	193
Figura 177. Beneficios de la librería Pandas	194
Figura 178. Otros beneficios de Pandas	194
Figura 179. Soportes para datos ens aries de tiempos	195
Figura 180. Estructura de datos en Pandas	195
Figura 181. Índices, arreglos y argumentos de Series y Dataframes	196
Figura 182. Pandas: soporte de muchos pasos	197

#### ÍNDICE DE TABLAS

Tabla 1.	Los resultados de la función <i>And</i>	39
Tabla 2.	Resultados del operador Or	39
Tabla 3.	Variables y factor de ponderación de precios de coches	125
Tabla 4.	Puntaje de coches usados de similares características	125
Tabla 5.	El flujo de tareas del proyecto Castillo de Edimburgo escrito con Project	186

#### Notas:

- 1. Se puede llegar a pensar que la estructuración de los capítulos 3 al 5 es un tanto inversa a lo que es el proceso natural de extracción de conocimientos a partir de datos, pero se hizo pensando en la ventaja de darle una naturaleza mucho más didáctica a los contenidos de los capítulos.
- 2. Algunas actividades de un proyecto se pueden repetir aún después de evaluar el resultado final y leer el informe definitivo. Ante la falta de conocimientos explícitos sobre las circunstancias propias de cada proyecto, las actividades que pudieran ser repetidas, son desconocidas y solo podrán ser reconocidas después de un análisis serio; naturalmente, son desconocidas al momento de desglosar el plan original.
- 3. Algunos capítulos, por su extenso contenido temático, pueden traer al final un Glosario de términos. Estos se elaboraron de acuerdo al contenido de cada capítulo. Igualmente es posible citar varias referencias bibliográficas en unos capítulos.

# Sistema de <u>Información en Línea</u>



Al final del libro encontrará el código para ingresar al **Sistema de información en Línea** - SIL - donde podrá descargar el proyecto en el último capítulo desarrollado en Microsoft Project.

# OBSERVACIONES GENERALES

La intención de esta obra es demostrar una metodología de desarrollo de investigaciones, proyectos e iniciativas aplicadas en muchas áreas del conocimiento que en diversas instancias se apoyan en cantidades acumuladas de información y datos provenientes de fuentes internas y externas en el marco de objetivos de sociedades abiertas al cambio. Agrega un repaso del lenguaje de programación **Python** muy utilizado en estos casos. El esquema didáctico general de este libro es demostrar las metodologías desarrolladas para estos proyectos.

La estructura organizativa dispone de funciones, algoritmos y metodologías hechos con **Python** y otras herramientas computacionales y con varias técnicas de corte administrativo y funcional. La Intención es facilitar los procesos de análisis con estas herramientas en diversos proyectos e investigaciones de acuerdo a un plan estratégico y sin que importe la extensión y la complejidad de los datos disponibles. Los ejercicios mostrados vienen en un formato de presentación que hace relativamente fácil su desarrollo y seguimiento.

Vale la pena resaltar como interesante de notar, que en los últimos treinta o cuarenta años han surgido una serie de herramientas computacionales que han facilitado de una manera automática y semi automática, convertir ese gran volumen de datos en *conocimiento* que de una forma u otra se aplica a fin de dar respuesta a diversas inquietudes, que es en lo que realmente se focaliza este libro. En el esquema de Anexos, se han dejado dos ejemplos sobre el uso de un par de librerías de Python



llamadas Numpy y Pandas, que demuestran el enorme poder en la concepción y manejo del recurso informático Python en estos proyectos.

Se hace un especial reconocimiento al **Project Management Institute** ( $PMI^{\text{\tiny IM}}$ ), por el uso detallado de principios generales y enfoques metodológicos que estableció para el manejo administrativo y gerencial de los proyectos. El **PMI** permanece como uno de los principales líderes en el uso y mantenimiento de mecanismos y valores aplicables en la gestión de proyectos de variada naturaleza.

Los valores y cifras empleados en los ejercicios y ejemplos de esta obra se muestran en divisas y monedas de un país hipotético, para que sean aplicables a diversos tipos de economías. Los ejercicios y ejemplos que se explican vienen en un formato de presentación que hace relativamente fácil su desarrollo y seguimiento. El lector puede crearlos y guardarlos en su computadora para luego analizar su contenido y adaptarlo a su gusto y conveniencia, si así lo desea. Esto le permitirá un mayor entendimiento y una mayor práctica que fortalezca sus conocimientos.

Las instrucciones relativas a herramientas de computación empleadas en esta obra se presentan, preferencialmente, en español, aunque es inevitable el uso y presencia de términos en inglés, dada su amplia aceptación en las labores profesionales propias de esta obra. Se señalan en negrilla los nombres de los menús o teclas de acceso rápido y en letra estándar las opciones que el usuario podrá o deberá indicar en cada instrucción.

En caso de que el usuario deba escoger una opción dentro de una lista de valores, esta aparecerá demarcada entre corchetes rectangulares ([...]) y si tiene que escribir un texto en particular, se señalará con la notación <...>. Las teclas de acceso rápido son opciones de un programa que se ejecutan con una combinación de dos teclas. Generalmente, primero se mantiene oprimida la tecla Ctrl y luego la tecla correspondiente a la letra que aparece subrayada en la opción respectiva (por ejemplo, Ctrl+O). Los nombres y opciones de un menú que aparezcan con una letra subrayada indican que se pueden ejecutar con esta combinación de teclas de acceso rápido. Es frecuente el uso de este tipo de notación: Vista  $\rightarrow$  Zoom  $\rightarrow$  Todo el programa para indicar la secuencia de pasos al usar opciones del menú.

El término *clic* se utiliza en este libro para aludir a la acción de presionar uno de los botones (generalmente el izquierdo) del dispositivo apuntador llamado comúnmente *mouse*, en el medio hispanoparlante. Algunos prefieren usar el término ratón en vez de *mouse*. Términos en inglés como *hardware* y *software*, que son de amplia aceptación en el mundo de la informática, se emplearán en esta obra para referir los componentes físicos y lógicos de computadores, respectivamente.

**Nota**: algunas gráficas y contenidos en la forma de tablas se diseñaron y se publican en este libro en un formato parecido al que se puede ver en los cursos del EdX, de donde proceden varios de ellos. Varios textos originales que aparecieron en inglés,

en los cursos, se tradujeron al castellano y se publicaron después de ser dirigida al EdX una previa nota por parte del autor de este libro, tal y como lo recomienda el mismo EdX y sus entidades patrocinadoras como la IBM.

Los términos, sobre todo de funciones y operadores de lenguajes de programación que se mencionan en inglés, solo se hace así por la mención original que se hizo en ese idioma y no es conveniente traducirlos a otros lenguajes por la amplia aceptación del inglés.